

Quarterly Report on Document Digitization

The archive contains roughly 12,400 scanned pages from the years 1952 to 1987. Most documents are typed letters, invoices and technical drawings. This sample page is used to compare OCR engines.

1. Methods

Each page is rendered at 300 DPI and passed to every engine. Word boxes are normalized to fractions of the page size, so the HTML overlay lines up with the background image at any zoom.

2. Results

Engine agreement is measured with the character error rate (CER) between every pair of engines; lower means closer to consensus.

Invoice No. 2024-0815, total amount: 1,234.56 EUR.

Bericht über die Digitalisierung

Größere Bestände wurden im Frühjahr gescannt. Die Qualität der Vorlagen schwankt stark: Durchschläge, Matrizenabzüge und handschriftliche Notizen erschweren die Texterkennung.

Übersicht der Schritte

Zunächst prüfen wir Umlaute (ä, ö, ü, Ä, Ö, Ü) und das ß.

Danach vergleichen wir die Ergebnisse aller Verfahren.

Straße, Maßnahme, Übergröße, Höhe, Äpfel, Öffnungszeiten.

Mit freundlichen Grüßen

Dr. Jürgen Müller, Köln